

Analisi dati di magazzino

Pulizia, analisi esplorativa e feature engineering con Python



AUTORE Simone Macelloni	AMBITO Data Analytics · Logistica	OUTPUT dataset_finale.csv
----------------------------	--------------------------------------	------------------------------

Documentazione per presentazione d'esame, portfolio professionale e curriculum vitae

01

Sintesi del progetto

Obiettivi, risultati e architettura della soluzione

Il progetto trasforma un export grezzo di inventario e vendite di un magazzino grocery in un dataset pulito, arricchito e utilizzabile per analisi di business e dashboard interattive. Il lavoro è stato sviluppato in due notebook Jupyter separati: il primo dedicato alla qualità del dato e il secondo all'analisi esplorativa e alla creazione di nuove variabili gestionali.

990 prodotti / SKU righe conservate	16 → 29 colonne 13 feature aggiunte	465 prodotti da attenzionare sotto soglia o sulla soglia	€ 132.851 riordini necessari stima su righe da attenzionare
--	--	---	--

Pipeline del progetto

Dal dato grezzo a un dataset arricchito, validato e pronto per la Business Intelligence.




Figura 1 - Pipeline end-to-end implementata nei notebook.

Risultato principale

La pipeline mantiene tutte le 990 osservazioni, corregge i problemi gestibili senza alterare arbitrariamente i dati e produce dataset_finale.csv con 29 colonne, pronto per il collegamento a Looker Studio.

Contenuti del documento

- Dataset, obiettivi e stack tecnologico
- Pulizia e preprocessing nel Notebook 01
- Analisi esplorativa e feature engineering nel Notebook 02
- Dizionario delle feature create
- Insight, raccomandazioni, limiti e uso dell'AI

02

Dataset, obiettivi e metodologia

Impostazione del project work didattico

Il dataset rappresenta un export sintetico di inventario e vendite relativo a un magazzino grocery multi-categoria. Ogni riga descrive un prodotto/SKU e integra informazioni su anagrafica, fornitore, stock, riordino, prezzo, date, vendite, rotazione e stato commerciale.

Area informativa	Colonne principali	Utilizzo nel progetto
Prodotto	Product_ID, Product_Name, Category	Identificazione e segmentazione merceologica
Fornitore	Supplier_ID, Supplier_Name	Analisi dei riordini e controllo della struttura anagrafica
Scorte	Stock_Quantity, Reorder_Level, Reorder_Quantity	Stato delle scorte, gap e fabbisogno di riordino
Economia	Unit_Price	Valore stimato dello stock e dei riordini
Tempo	Date_Received, Last_Order_Date, Expiration_Date	Controlli di coerenza, senza inferenze sui lotti
Vendite	Sales_Volume, Inventory_Turnover_Rate	Classi di domanda, rotazione e rischio gestionale
Stato	Status, Warehouse_Location	Analisi operativa e verifica della qualità descrittiva

Obiettivi operativi

1. Ottenere un dataset pulito, coerente nei tipi e documentato nelle anomalie.
2. Creare indicatori utili alla gestione di stock, riordini, fornitori e vendite.
3. Distinguere domanda e rotazione con soglie ricavate dalla distribuzione reale dei dati.
4. Costruire una segnalazione prudente del rischio di obsolescenza senza inventare informazioni non presenti.
5. Esportare un CSV finale riutilizzabile come sorgente di Business Intelligence.

Stack tecnologico

Strumento	Ruolo
Python 3 / Jupyter Notebook	Esecuzione documentata e riproducibile della pipeline.
pandas	Importazione, controllo, trasformazione, aggregazioni ed esportazione.
NumPy	Classificazioni condizionali e supporto numerico.
Matplotlib / Seaborn	Analisi grafica e comunicazione dei risultati.
CSV	Formato interoperabile tra Python e strumenti BI.
Looker Studio	Destinazione prevista per la dashboard; non oggetto di validazione nei notebook allegati.

Principio metodologico

Le correzioni sono state applicate solo quando supportate dal contesto del dataset. Le anomalie non risolvibili - in particolare quelle relative alle date e ai lotti - sono state segnalate e documentate, non "aggiustate" in modo arbitrario.

03

Notebook 01 - Pulizia e preparazione

Data quality, tipizzazione e output intermedio

Il primo notebook parte da Dataset.csv e costruisce Dataset_pulito.csv. La sequenza di controlli è stata organizzata per rendere visibile ogni decisione: ispezione iniziale, gestione dei valori mancanti, verifica delle chiavi, pulizia testuale, conversione di prezzi e date, analisi delle incoerenze e controllo degli outlier.

Controlli di qualità eseguiti

Problemi identificati, gestiti o documentati nel notebook di pulizia.



Figura 2 - Sintesi dei principali controlli di qualità.

Interventi implementati

Controllo	Esito / modifica	Motivazione
Refuso di schema	Catagory → Category	Correzione del nome della colonna per coerenza semantica e uso successivo.
Valore mancante	Categoria di Cabbage, Product_ID 10-378-9729	Assegnazione a Fruits & Vegetables dopo verifica del prodotto.
Duplicati	0 righe e 0 Product_ID duplicati	Nessuna rimozione; integrità del numero di osservazioni preservata.
Testi	Rimozione di spazi iniziali/finali	Uniformazione delle colonne categoriche e identificative.
Prezzo	Unit_Price da testo con simbolo \$ a numerico	Conversione necessaria per calcoli economici e statistiche.
Date	Conversione MM/DD/YYYY → datetime	Tipizzazione di Date_Received, Last_Order_Date ed Expiration_Date.
Anomalie temporali	496 scadenze precedenti alla ricezione	Record segnalati; nessuna correzione per assenza di Lot_ID/Batch_ID.
Outlier	Metodo IQR su Unit_Price	Valori estremi mantenuti perché potenzialmente plausibili.

Esempio di trasformazione

```
# Rimozione del simbolo $ e conversione numerica
df['Unit_Price'] = pd.to_numeric(
    df['Unit_Price'].str.replace('$', '', regex=False).str.strip(),
    errors='coerce'
)
```

Decisione di qualità


Le 496 incoerenze temporali non sono state interpretate come errori certi. Senza un identificativo di lotto non è possibile dimostrare che Date_Received ed Expiration_Date descrivano la stessa fornitura.

04

Notebook 02 - EDA e gestione scorte

Distribuzioni, soglie di riordino e valore economico

Il secondo notebook carica Dataset_pulito.csv, analizza la composizione del catalogo e crea le feature necessarie alla dashboard. L’analisi iniziale evidenzia la concentrazione merceologica e la distribuzione degli stati commerciali; successivamente il focus si sposta sul rapporto tra quantità disponibile e soglia di riordino.



La categoria Fruits & Vegetables è la più rappresentata (332 prodotti). Sul fronte scorte, 455 prodotti sono sotto la soglia di riordino, 10 sono esattamente sulla soglia e 525 dispongono di una scorta superiore al livello impostato.

Feature operative per le scorte

Feature	Logica	Utilità
Product_Label	Product_Name + Product_ID	Evita sovrapposizioni nei grafici quando il nome prodotto si ripete.
Supply_Status	Confronto Stock_Quantity / Reorder_Level	Classifica ogni riga in Da riordinare, Sulla soglia o Scorta sufficiente.
Stock_Gap	Stock_Quantity - Reorder_Level	Ordina le urgenze: valori più negativi indicano deficit maggiori.
Units_To_Reorder_Level	max(Reorder_Level - Stock_Quantity, 0)	Quantifica le unità mancanti per tornare almeno alla soglia.
Stock_Reorder_Ratio	Stock_Quantity / Reorder_Level	Normalizza il confronto: <1 sotto soglia, =1 sulla soglia, >1 sopra soglia.

Misure economiche

€ 332.655 valore stock somma Inventory_Value	€ 336 valore medio / riga media Inventory_Value	€ 305.485 riordino teorico totale tutte le righe	€ 132.851 riordino necessario solo righe da attenzionare
---	--	---	---


Inventory_Value e Estimated_Reorder_Cost sono stime basate su Unit_Price. Il dataset non specifica se il campo rappresenti costo d’acquisto o prezzo di vendita; per questo i risultati vengono presentati come valori indicativi, non come costi contabili.

05

Fornitori e vendite

Aggregazioni, indicatori binari e classi di domanda

L'analisi dei fornitori ha richiesto una verifica preliminare della struttura anagrafica. Sono presenti 990 Supplier_ID distinti, uno per riga, ma soltanto 350 Supplier_Name. Di conseguenza il nome del fornitore è stato utilizzato come dimensione aggregabile, documentando il limite di qualità della chiave.



Feedbug, Browsecat e Viva presentano i valori aggregati più elevati di Reorder_Cost_Required. Sul fronte vendite, Seafood e Bakery registrano il volume medio per prodotto più alto; la categoria Fruits & Vegetables genera il maggiore volume totale anche perché contiene il numero più elevato di SKU.

Feature implementate per fornitori e domanda

Feature	Definizione	Uso in Looker Studio
Reorder_Needed_Flag	1 se Da riordinare o Sulla soglia; altrimenti 0	Somma dei prodotti che richiedono attenzione per fornitore/categoria.
Reorder_Cost_Required	Estimated_Reorder_Cost × Reorder_Needed_Flag	Costo stimato riferito esclusivamente alle righe che richiedono attenzione.
Backordered_Flag	1 se Status = Backordered	Conteggio semplice degli articoli arretrati, senza attribuire la causa al fornitore.
Demand_Class	Quantili 33% e 67% di Sales_Volume	Filtro a tre livelli: domanda bassa, media e alta.

Soglie della domanda

Nel dataset le soglie calcolate sono 46 e 71. I prodotti con Sales_Volume ≤ 46 sono classificati a domanda bassa; quelli tra 47 e 71 a domanda media; quelli oltre 71 a domanda alta.

Interpretazione corretta di Backordered

Lo stato Backordered segnala una disponibilità arretrata o insufficiente, ma non dimostra da solo una responsabilità del fornitore: mancano dati su lead time, ordini aperti e cause operative.


06

Rotazione e rischio di obsolescenza

Classificazioni relative e indicatore gestionale

Inventory_Turnover_Rate è presente nel dataset originale, ma non è accompagnato da formula o periodo di riferimento. È stato quindi trattato come indice relativo: utile per confrontare i prodotti tra loro, non per affermare quante volte la scorta venga rinnovata in un anno.

Distribuzione delle classi di rotazione



Rischio gestionale di obsolescenza



La rotazione media è 50,15, con mediana 50 e deviazione standard 28,80. Il primo quartile è 25 e il terzo quartile 74,75: queste soglie generano 251 prodotti a rotazione bassa, 491 a rotazione media e 248 a rotazione alta.

Regola del rischio di obsolescenza

Domanda	Rotazione	Classe assegnata
Bassa	Bassa	Rischio alto
Bassa	Media o alta	Rischio medio
Media o alta	Bassa	Rischio medio
Media o alta	Media o alta	Rischio basso

Il risultato identifica 96 prodotti a rischio alto, 396 a rischio medio e 498 a rischio basso. Il valore stimato dello stock associato al rischio alto è circa € 32.597. Inventory_Value viene usato per quantificare l'esposizione economica, non per determinare automaticamente il livello di rischio.

```
def classifica_rischio_obsolescenza(riga):
    domanda_bassa = riga['Demand_Class'] == 'Domanda bassa'
    rotazione_bassa = riga['Turnover_Class'] == 'Rotazione bassa'

    if domanda_bassa and rotazione_bassa:
        return 'Rischio alto'
    elif domanda_bassa or rotazione_bassa:
        return 'Rischio medio'
    return 'Rischio basso'
```

Natura dell'indicatore

Obsolescence_Risk è una regola gestionale interpretabile, non un modello predittivo. Non stima una probabilità futura e non utilizza le date di scadenza, considerate non affidabili a livello di lotto.

07

Dizionario delle feature create

Da 16 colonne originali a 29 colonne finali

Le 13 nuove variabili sono state aggiunte al DataFrame principale e quindi esportate nel CSV finale. Le tabelle aggregate utilizzate nei notebook per analisi e grafici non sono state replicate riga per riga, evitando ridondanze e mantenendo il dataset adatto a Looker Studio.

Feature	Tipo	Formula / logica	Finalità
Product_Label	Testo	Product_Name + " " + Product_ID	Etichetta univoca per grafici e tabelle.
Supply_Status	Categorica	Stock vs Reorder_Level	Stato delle scorte in tre classi.
Stock_Gap	Numerica	Stock_Quantity - Reorder_Level	Distanza assoluta dalla soglia.
Inventory_Value	Numerica	Stock_Quantity × Unit_Price	Valore economico stimato dello stock.
Estimated_Reorder_Cost	Numerica	Reorder_Quantity × Unit_Price	Valore teorico della quantità di riordino.
Units_To_Reorder_Level	Numerica	max(Reorder_Level - Stock_Quantity, 0)	Unità mancanti per raggiungere la soglia.
Stock_Reorder_Ratio	Numerica	Stock_Quantity / Reorder_Level	Confronto normalizzato tra stock e soglia.

Esempio di logica condizionale

```
condizioni = [
    df['Stock_Quantity'] < df['Reorder_Level'],
    df['Stock_Quantity'] == df['Reorder_Level']
]

df['Supply_Status'] = np.select(
    condizioni,
    ['Da riordinare', 'Sulla soglia'],
    default='Scorta sufficiente'
)
```

Scelta progettuale

Le feature riga-per-riga sono esportate perché riutilizzabili come dimensioni e metriche. Le aggregazioni per fornitore, categoria o classe restano dinamiche e vengono ricostruite nello strumento BI.

08

Feature finali e validazione

Indicatori binari, classi e controllo dell'output

Feature	Tipo	Formula / logica	Finalità
Reorder_Needed_Flag	Binaria	1 se Supply_Status è Da riordinare o Sulla soglia	Conteggio aggregabile delle righe da attenzionare.
Reorder_Cost_Required	Numerica	Estimated_Reorder_Cost × flag	Costo stimato dei riordini effettivamente necessari.
Backordered_Flag	Binaria	1 se Status = Backordered	Conteggio aggregabile degli articoli arretrati.
Demand_Class	Categorica	Quantili 33% e 67% di Sales_Volume	Domanda bassa, media o alta.
Turnover_Class	Categorica	Quartili 25% e 75% di Inventory_Turnover_Rate	Rotazione bassa, media o alta.
Obsolescence_Risk	Categorica	Combinazione Demand_Class + Turnover_Class	Segnalazione gestionale in tre livelli.

Controlli finali eseguiti

990 righe finali nessuna perdita di record	29 colonne finali 16 originali + 13 nuove	0 feature mancanti controllo elenco previsto	0 valori nulli nelle feature create
---	--	---	--

La pipeline è stata validata tramite riesecuzione sequenziale dei due notebook. Il primo genera Dataset_pulito.csv; il secondo ricarica tale file, ricrea tutte le feature e produce dataset_finale.csv con codifica UTF-8-SIG e date nel formato YYYY-MM-DD.

```
file_output = Path('dataset_finale.csv')

df.to_csv(
    file_output,
    index=False,
    date_format='%Y-%m-%d',
    encoding='utf-8-sig'
)
```

Struttura suggerita per Looker Studio

Elemento dashboard	Dimensione	Metriche
Stato scorte	Supply_Status / Category	Conteggio prodotti, Stock_Gap, Units_To_Reorder_Level
Fornitori	Supplier_Name	SUM(Reorder_Needed_Flag), SUM(Reorder_Cost_Required), SUM(Backordered_Flag)
Valore inventario	Category / Product_Label	SUM(Inventory_Value), media e top prodotti
Vendite	Demand_Class / Category	SUM e AVG(Sales_Volume)
Rotazione e rischio	Turnover_Class / Obsolescence_Risk	Conteggio prodotti e SUM(Inventory_Value)

09

Insight e raccomandazioni operative

Dal risultato numerico alla decisione di business

Gli insight riportati derivano dalle elaborazioni contenute nei notebook e dal dataset finale. Le raccomandazioni sono formulate in modo coerente con la natura sintetica e descrittiva dei dati.

Insight principali**47,0% del catalogo richiede attenzione**

465 prodotti sono sotto soglia o esattamente sulla soglia; 455 risultano già da riordinare.

€ 132.851 di riordino stimato necessario

La misura esclude le righe con scorta sufficiente e concentra l'analisi sul fabbisogno operativo.

Rischio alto circoscritto ma economicamente rilevante

96 prodotti, pari al 9,7% del catalogo, sono a domanda bassa e rotazione bassa; il relativo stock vale circa € 32.597.

Struttura fornitori da normalizzare

Supplier_ID è univoco per riga e non consente il raggruppamento; Supplier_Name è stato usato come soluzione disponibile.

Domanda e stock non mostrano un legame forte

La quota di prodotti da riordinare è simile nelle tre classi di domanda; la soglia di riordino potrebbe non essere calibrata sul comportamento delle vendite.

Raccomandazioni

1. Priorità di riordino multilivello - Ordinare le attività combinando Stock_Gap, Units_To_Reorder_Level e Reorder_Cost_Required, evitando una semplice lista binaria di prodotti sotto soglia.

2. Revisione delle soglie - Confrontare Reorder_Level con Sales_Volume e Demand_Class. La distribuzione simile dei riordini tra domanda alta e bassa suggerisce soglie non pienamente aderenti al consumo.

3. Piano per i prodotti a rischio alto - Esaminare i 96 prodotti con domanda e rotazione basse, partendo da quelli con Inventory_Value maggiore: promozioni, riduzione degli ordini o revisione dell'assortimento.

4. Normalizzazione delle anagrafiche - Introdurre un Supplier_ID stabile, ubicazioni di magazzino strutturate e Lot_ID/Batch_ID per rendere affidabili analisi su lead time, scadenze e responsabilità operative.

Limiti del dataset e dell'analisi

- Il dataset è sintetico e alcune relazioni possono non riflettere un gestionale reale.
- Unit_Price non è definito con certezza come costo di acquisto o prezzo di vendita.
- Supplier_ID non è una chiave stabile per il fornitore; Warehouse_Location è praticamente univoca per riga.
- Inventory_Turnover_Rate non specifica formula né periodo di riferimento.
- L'assenza di Lot_ID/Batch_ID impedisce un'analisi affidabile di shelf life e scadenze.
- Obsolescence_Risk è una regola euristica descrittiva, non un modello predittivo.

Utilizzo dell'Intelligenza Artificiale

ChatGPT (OpenAI) è stato utilizzato come assistente didattico nelle fasi di chiarimento delle funzioni pandas, generazione e revisione del codice, debug della sequenza di esecuzione, discussione delle feature, scelta delle visualizzazioni e revisione della documentazione. Le trasformazioni sono state eseguite nei notebook e validate sui dati; le decisioni metodologiche finali, compresa la scelta di non inferire informazioni sui lotti, sono state mantenute esplicite e verificabili.

Ruolo dell'autore

L'AI ha supportato apprendimento e revisione. La responsabilità della struttura del progetto, dell'esecuzione, dell'interpretazione e della presentazione resta dell'autore.

Competenze dimostrate nel portfolio

Competenza	Evidenza nel progetto
Data cleaning	Valori mancanti, duplicati, refusi, spazi, conversione di tipi e gestione prudente delle anomalie.
Analisi esplorativa	Statistiche descrittive, distribuzioni, aggregazioni e comparazioni per categorie.
Feature engineering	Indicatori numerici, flag binari e classificazioni basate su soglie statistiche.
Business analysis	Traduzione dei calcoli in KPI, insight e raccomandazioni operative.
Data visualization	Grafici leggibili e orientati a un pubblico non tecnico.
Reproducibilità	Pipeline divisa in notebook, output intermedi e CSV finale interoperabile.
Data governance	Documentazione dei limiti e rifiuto di correzioni non supportate.

11

Conclusione e deliverable

Stato del progetto e riuso nel portfolio

Il project work documenta una pipeline completa lato Python: dal controllo del dato grezzo alla produzione di un dataset arricchito. Il risultato è tecnicamente leggibile, riproducibile e orientato all'uso in Business Intelligence. La scelta di separare pulizia e feature engineering in due notebook rende il processo più chiaro per la valutazione didattica e più facilmente presentabile in un portfolio.

2 notebook Jupyter pipeline separata per fasi	2 dataset prodotti pulito + finale	13 feature create pronte per aggregazioni BI	4 raccomandazioni orientate alla gestione
--	---	---	--

Deliverable documentati

File / output	Contenuto	Stato
01_pulizia_dati_magazzino.ipynb	Ispezione, pulizia, controlli e Dataset_pulito.csv	Completato
02_analisi_esplorativa_feature_eng.ipynb	EDA, feature engineering, grafici e dataset_finale.csv	Completato
Dataset_pulito.csv	Dataset tipizzato e corretto, 990 × 16	Completato
dataset_finale.csv	Dataset arricchito, 990 × 29	Completato
Dashboard Looker Studio	Report interattivo basato sul CSV finale	Fase successiva / sorgente pronta
Documentazione PDF	Metodologia, risultati, limiti e raccomandazioni	Completato

Presentazione sintetica per CV / LinkedIn

Project Work - Warehouse Data Analytics

Sviluppo di una pipeline Python per la pulizia e l'analisi di 990 SKU di magazzino. Creazione di 13 feature relative a stock, riordini, valore inventario, domanda, rotazione e rischio di obsolescenza; esportazione di un dataset finale a 29 colonne pronto per Looker Studio.

Chiusura

Il progetto dimostra la capacità di affrontare un dataset non perfetto, motivare le scelte di pulizia, costruire indicatori interpretabili e collegare l'analisi tecnica a esigenze operative di magazzino. Il valore del lavoro non risiede soltanto nei grafici o nelle formule, ma nella tracciabilità delle decisioni e nella consapevolezza dei limiti del dato.

FINE DOCUMENTO